

# Homework 02

最大似然参数估计、非参数技术、多维正态分布

## Homework 2.1

设  $\mathbf{x}$  为一个  $d$  维的二值向量（即其分量取值为 0 或 1），服从多维伯努利分布

$$p(\mathbf{x} | \Theta) = \prod_{i=1}^d \Theta_i^{x_i} (1 - \Theta_i)^{1-x_i}$$

其中  $\Theta = (\Theta_1, \dots, \Theta_d)^T$  是未知的参数向量，而  $\Theta_i$  为  $x_i=1$  的概率。证明，对于  $\Theta$  的最大似然估计为

$$\hat{\Theta} = \frac{1}{n} \sum_{k=1}^n \mathbf{x}_k, \quad n \text{ 为样本数}$$

### Homework 2.1

证明： 假设数据集  $D = \{\vec{X}_1, \vec{X}_2, \dots, \vec{X}_n\}$ ,  $n$  为样本数  
由题可知  $\vec{X}_k, k = 1, 2, \dots, n$  服从多维伯努利分布。  
即  $P(\vec{X}_k | \vec{\Theta}) = \prod_{i=1}^d \Theta_i^{x_{ki}} (1 - \Theta_i)^{1-x_{ki}}$ , 其中  $d$  为  $X_k$  的  
维度  $d$ .  $x_{ki}$  为第  $k$  个样本的第  $i$  维  
而  $\Theta_i$  为  $X_{ki}=1$  的概率。

则样本观测值的概率为：

$$P(D | \vec{\Theta}) = \prod_{k=1}^n P(\vec{X}_k | \vec{\Theta})$$

那么  $\vec{\Theta}$  的极大似然估计即求使得  $P(D | \vec{\Theta})$  最大的  $\vec{\Theta}$ .

对  $P(D | \vec{\Theta})$  求对数得：

$$\ln P(D | \vec{\Theta}) = \sum_{k=1}^n \ln P(\vec{X}_k | \vec{\Theta})$$

∴ 对数函数是单调的，求对数后极值保持一致，那么  
我们求得  $P(D | \vec{\Theta})$  最大的  $\vec{\Theta}$  即求  $\ln P(D | \vec{\Theta})$  的极值。

因此对  $\text{Inp}(D|\vec{\theta})$  求导可得：

$$\frac{\partial \text{Inp}(D|\vec{\theta})}{\partial \vec{\theta}} = \frac{\partial \sum_{k=1}^n \text{Inp}(\vec{X}_k | \vec{\theta})}{\partial \vec{\theta}}$$

$$\therefore p(\vec{X}_k | \vec{\theta}) = \prod_{i=1}^d \theta_i^{x_{ki}} (1-\theta_i)^{1-x_{ki}}$$

$$\therefore \frac{\partial \text{Inp}(D|\vec{\theta})}{\partial \vec{\theta}} = \frac{\partial \sum_{k=1}^n \sum_{i=1}^d x_{ki} \ln \theta_i + (1-x_{ki}) \ln (1-\theta_i)}{\partial \vec{\theta}}$$

$$= \sum_{i=1}^d \left[ \frac{\partial \sum_{k=1}^n x_{ki} \ln \theta_i + (1-x_{ki}) \ln (1-\theta_i)}{\partial \theta_i} \right]$$

$$= \sum_{i=1}^d \sum_{k=1}^n \left( \frac{x_{ki}}{\theta_i} - \frac{1-x_{ki}}{1-\theta_i} \right)$$

$$= \sum_{i=1}^d \sum_{k=1}^n \frac{x_{ki} - x_{ki}\theta_i - \theta_i + x_{ki}\theta_i}{\theta_i(1-\theta_i)}$$

$$= \sum_{i=1}^d \sum_{k=1}^n \frac{x_{ki} - \theta_i}{\theta_i(1-\theta_i)}$$

$$= \sum_{k=1}^n \frac{\vec{X}_k - \vec{\theta}}{\theta(1-\theta)}$$

令导数为零可得： $\sum_{k=1}^n (\vec{X}_k - \vec{\theta}) = 0$

$$\therefore \sum_{k=1}^n \vec{X}_k - n \vec{\theta} = 0$$

$$\Rightarrow \vec{\theta} = \frac{1}{n} \sum_{k=1}^n \vec{X}_k$$

因此得证。 $\vec{\theta}$  的最大似然估计为  $\vec{\theta} = \frac{1}{n} \sum_{k=1}^n \vec{X}_k$ ,  $n$  为样本数

## Homework 2.2

令  $D = \{x_1, \dots, x_n\}$  为  $n$  个独立的已标记的集合。令  $D_k(x) = \{x'_1, \dots, x'_k\}$  为样本  $x$  的  $k$  个最邻近。根据  $k$ -近邻规则,  $x$  将归入  $D_k(x)$  中出现次数最多的那个类别。

考虑一个 2 类别问题, 先验概率为  $P(\omega_1) = P(\omega_2) = 1/2$ 。进一步假设类条件概率密度  $P(X | \omega_i)$  在 10 单位超球体内为均匀分布。

(a) 证明如果  $k$  为奇数, 那么平均误差率为

$$P_n(e) = \frac{1}{2^n} \sum_{j=0}^{(k-1)/2} \binom{n}{j}$$

Homework 2.2

(a) 证明: 设样本  $x$  的类别为  $\omega_1$ , 那么  $x$  若在  $k$ -近邻中被归入  $\omega_2$  则出现误差。

而根据  $k$ -近邻规则,  $x$  将归入  $D_k(x)$  中出现次数最多的那个类别。

假设  $D_k(x)$  中出现  $j$  个  $\omega_1$  类别的样本。当样本数  $n$  较大时, 可以认为是随机抽取了  $j$  个  $\omega_1$  类别样本。(因为类概率密度  $P(X | \omega_i)$  在 10 单位超球体内均匀分布。)

而已知  $P(\omega_1) = P(\omega_2) = \frac{1}{2}$  且  $k$  为奇数, 则平均误差率为:

$$P_n(e) = \sum_{j=0}^{(k-1)/2} \binom{n}{j} p(\omega_1)^j p(\omega_2)^{n-j}$$

$$= \sum_{j=0}^{(k-1)/2} \binom{n}{j} \left(\frac{1}{2}\right)^n$$

$$= \frac{1}{2^n} \sum_{j=0}^{(k-1)/2} \binom{n}{j}$$

即  $D_k(x)$  中有少于等于  $(k-1)/2$  的为  $\omega_1$  类别则样本  $x$  会被误归入  $\omega_2$  类别。同理, 若设样本  $x$  的类别为  $\omega_2$ , 那样本被

误归入  $W_1$  类别的概率也同相，因此若  $k$  为奇数，平均误差率为  $P_n(e) = \frac{1}{2^n} \sum_{j=0}^{(k-1)/2} \binom{n}{j}$  得证。

(b) 证明在这种情况下，如果  $k > 1$ ，那么最近邻规则比  $k$ -近邻规则有更低的误差率。

(b) 最近邻规则的平均误差率即为  $k=1$  代入(a)式：

$$P_n(e) = \frac{1}{2^n} \sum_{j=0}^{\frac{k}{2}} \binom{n}{j} = \frac{1}{2^n}$$

当  $k$  为奇数时

而  $k > 1$  时，平均误差率为：

$$P_n(e) = \frac{1}{2^n} \sum_{j=0}^{(k-1)/2} \binom{n}{j}$$

$$= \frac{1}{2^n} \left[ \sum_{j=0}^0 \binom{n}{j} + \sum_{j=1}^{(k-1)/2} \binom{n}{j} \right]$$

$$= \frac{1}{2^n} \left[ 1 + \sum_{j=1}^{(k-1)/2} \binom{n}{j} \right]$$

$$= \frac{1}{2^n} + \frac{1}{2^n} \sum_{j=1}^{(k-1)/2} \binom{n}{j}$$

$$> \frac{1}{2^n}$$

由(a)中同理，当  $k$  为偶数时，平均误差率为：

$$P_n(e) = \frac{1}{2^n} \sum_{j=0}^{\frac{k}{2}-1} \binom{n}{j}$$

$$= \frac{1}{2^n} \left[ \sum_{j=0}^0 \binom{n}{j} + \sum_{j=1}^{\frac{k}{2}-1} \binom{n}{j} \right]$$

$$= \frac{1}{2^n} + \frac{1}{2^n} \sum_{j=1}^{\frac{k}{2}-1} \binom{n}{j}$$

$$> \frac{1}{2^n}$$

因此， $k > 1$ ，最近邻规则比  $k$ -近邻规则有更低的误差率得证。

(c) 如果  $k$  随着  $n$  的增加而增加, 同时又受  $k < a\sqrt{n}$  的限制, 那么证明:

当  $n \rightarrow \infty$  时  $P_n(e) \rightarrow 0$ 。

(c) 证明: 首先展开错误率计算公式: (在偶数情况下奇数同理)

$$P_n(e) = \frac{1}{2^n} \sum_{j=0}^{\lfloor n/2 \rfloor - 1} \binom{n}{j}$$

$$= \frac{1}{2^n} \sum_{j=0}^{\lfloor n/2 \rfloor - 1} \frac{n!}{j!(n-j)!}$$

$$= \frac{1}{2^n} \binom{n}{0} + \frac{1}{2^n} \binom{n}{1} + \dots + \frac{1}{2^n} \binom{n}{\lfloor n/2 \rfloor - 1}$$

对于组合数而言, 当  $j < \frac{n}{2}$  的时候,  $\binom{n}{j}$  递增, 同时题中  $k < a\sqrt{n}$

$$\therefore \frac{1}{2^n} \binom{n}{0} < \frac{1}{2^n} \binom{n}{1} < \dots < \frac{1}{2^n} \binom{n}{\lfloor a\sqrt{n}/2 \rfloor - 1}$$

对于任意  $\varepsilon > 0$ , 我们可以有:

$$\frac{1}{2^n} \times \frac{n!}{(\lfloor a\sqrt{n}/2 \rfloor - 1)! (n - \lfloor a\sqrt{n}/2 \rfloor + 1)!} < \varepsilon$$

$$\therefore \frac{1}{2^n} \binom{n}{0} < \frac{1}{2^n} \binom{n}{1} < \dots < \frac{1}{2^n} \binom{n}{\lfloor a\sqrt{n}/2 \rfloor - 1} < \varepsilon$$

$$\text{即: } \lim_{n \rightarrow +\infty} \frac{1}{2^n} \binom{n}{j} = 0$$

$$\therefore \lim_{n \rightarrow +\infty} P_n(e) = \sum_{j=0}^{\lfloor n/2 \rfloor - 1} \lim_{n \rightarrow +\infty} \frac{1}{2^n} \binom{n}{j}$$

$$= \sum_{j=0}^{\lfloor n/2 \rfloor - 1} (0)$$

$$= 0$$

因此, 当  $n \rightarrow +\infty$  时,  $P_n(e) \rightarrow 0$  得证。

## Homework 2.3

考慮三維正態分布  $p(\mathbf{x}|\omega) \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , 其中

$$\boldsymbol{\mu} = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} \quad \text{及} \quad \boldsymbol{\Sigma} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 5 & 2 \\ 0 & 2 & 5 \end{pmatrix}$$

(a) 求點  $\mathbf{x}_0 = (0.5, 0, 1)^t$  处的概率密度;

(a) 點  $\vec{x}_0 = \begin{pmatrix} 0.5 \\ 0 \\ 1 \end{pmatrix}$  处的機率密度為: (下面的上標  $t$  均為轉置  
參照的是題圖寫法)

$$P(\vec{x}_0 | \omega) = \frac{1}{(2\pi)^{\frac{3}{2}} |\vec{\Sigma}|^{\frac{1}{2}}} e^{-\frac{1}{2}(\vec{x}_0 - \vec{\mu})^t \vec{\Sigma}^{-1} (\vec{x}_0 - \vec{\mu})}$$

$$\because \vec{\Sigma} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 5 & 2 \\ 0 & 2 & 5 \end{pmatrix} \quad \therefore |\vec{\Sigma}|^{\frac{1}{2}} = \sqrt{\begin{vmatrix} 1 & 0 & 0 \\ 0 & 5 & 2 \\ 0 & 2 & 5 \end{vmatrix}} = \sqrt{1 \cdot 5 \cdot 2} = \sqrt{21}$$

$$\text{而 } \vec{\Sigma}^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 5 & 2 \\ 0 & 2 & 5 \end{pmatrix}^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{5} & \frac{2}{5} \\ 0 & \frac{2}{5} & \frac{1}{5} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{21} & -\frac{2}{21} \\ 0 & -\frac{2}{21} & \frac{5}{21} \end{pmatrix}$$

$$\therefore -\frac{1}{2}(\vec{x}_0 - \vec{\mu})^t \vec{\Sigma}^{-1} (\vec{x}_0 - \vec{\mu})$$

$$= -\frac{1}{2} \times \left[ \begin{pmatrix} 0.5 \\ 0 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} \right]^t \times \begin{pmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{21} & -\frac{2}{21} \\ 0 & -\frac{2}{21} & \frac{5}{21} \end{pmatrix} \times \left[ \begin{pmatrix} 0.5 \\ 0 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} \right]$$

$$= -\frac{1}{2} \times \begin{pmatrix} -0.5 \\ -2 \\ -1 \end{pmatrix}^t \times \begin{pmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{21} & -\frac{2}{21} \\ 0 & -\frac{2}{21} & \frac{5}{21} \end{pmatrix} \times \begin{pmatrix} -0.5 \\ -2 \\ -1 \end{pmatrix}$$

$$= -\frac{1}{2} \times \begin{pmatrix} -0.5 \\ -\frac{8}{21} \\ -\frac{1}{21} \end{pmatrix}^t \times \begin{pmatrix} -0.5 \\ -2 \\ -1 \end{pmatrix}$$

$$= -\frac{1}{2} \times (0.25 + \frac{16}{21} + \frac{1}{21}) = -0.53$$

$$\therefore p(\vec{x}_0 | \omega) = \frac{1}{(2\pi)^{\frac{3}{2}} \times \sqrt{2}} e^{-0.53}$$

$\approx 0.00816$

(b) 构造白化变换矩阵  $A_\omega$  ( $A_\omega = \Phi \Lambda^{-1/2}$ )，计算分别表示本征向量和本征值的矩阵  $\Phi$  和  $\Lambda$ ；然后，将此分布转换为以原点为中心协方差矩阵为单位阵的分布，即  $p(x|\omega) \sim N(\mathbf{0}, I)$ ；

(b) 全特征方程(本征方程)为0. 那  $|\vec{\Sigma} - \lambda \vec{I}| = 0$  可得：

$$\begin{vmatrix} 1-\lambda & 0 & 0 \\ 0 & 5-\lambda & 2 \\ 0 & 2 & 5-\lambda \end{vmatrix} = (1-\lambda)[(5-\lambda)^2 - 4] = 0$$

解得： $\lambda_1 = 1, \lambda_2 = 3, \lambda_3 = 7$ .

那么特征矩阵(本征矩阵)即为： $\vec{\Lambda} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 7 \end{pmatrix}$

那么将特征值  $\lambda_1, \lambda_2, \lambda_3$  分别代入  $\vec{\lambda}(\vec{\Sigma} - \lambda \vec{I}) \vec{x} = 0$  可得：

特征向量  $\vec{\phi}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad \vec{\phi}_2 = \begin{pmatrix} 0 \\ \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} \end{pmatrix}, \quad \vec{\phi}_3 = \begin{pmatrix} 0 \\ \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{pmatrix}$

$\therefore$  特征向量矩阵为  $\vec{\Phi} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ 0 & -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix}$

且  $\vec{A}_\omega = \vec{\Phi} \vec{\Lambda}^{-\frac{1}{2}} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \frac{\sqrt{6}}{6} & \frac{\sqrt{14}}{14} \\ 0 & -\frac{\sqrt{6}}{6} & \frac{\sqrt{14}}{14} \end{pmatrix}$

同时， $\vec{Y} = \vec{A}_\omega^t (\vec{x} - \vec{\mu}) \sim N(\mathbf{0}, \vec{I})$  可将原分布转换为  $N(\mathbf{0}, \vec{I})$ 。  
(指  $\vec{A}_\omega$  的位置)

(c) 将整个同样的转换过程应用于点  $\mathbf{x}_0$  以产生一变换点  $\mathbf{x}_w$ ;

(c) 通过 (b) 的转换而得:

$$\vec{x}_w = \vec{A}_w^t (\vec{x}_0 - \vec{\mu})$$

$$= \begin{pmatrix} 1 & 0 & 0 \\ 0 & \frac{\sqrt{10}}{4} & \frac{\sqrt{10}}{4} \\ 0 & -\frac{\sqrt{10}}{6} & \frac{\sqrt{10}}{4} \end{pmatrix}^t \times \left[ \begin{pmatrix} 0.5 \\ 0 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} \right]$$

$$= \begin{pmatrix} -0.5 \\ -\frac{1}{6} \\ -\frac{3\sqrt{10}}{14} \end{pmatrix}$$

(d) 通过详细计算, 证明原分布中从  $\mathbf{x}_0$  到均值  $\boldsymbol{\mu}$  的 Mahalanobis 距离与变换后的分布中从  $\mathbf{x}_w$  到  $\mathbf{0}$  的 Mahalanobis 距离相等;

(d) 原分布中  $\vec{x}_0$  到均值  $\vec{\mu}$  的 Mahalanobis 距离为:

$$(\vec{x}_0 - \vec{\mu})^t \vec{\Sigma}^{-1} (\vec{x}_0 - \vec{\mu}) \quad (\vec{\Sigma}^{-1} \text{已在 (a) 中算出})$$

$$= \begin{pmatrix} -0.5 \\ -2 \\ -1 \end{pmatrix}^t \times \begin{pmatrix} 1 & 0 & 0 \\ 0 & \frac{5}{21} & -\frac{2}{21} \\ 0 & -\frac{2}{21} & \frac{5}{21} \end{pmatrix} \times \begin{pmatrix} -0.5 \\ -2 \\ -1 \end{pmatrix}$$

$$= \begin{pmatrix} -0.5 \\ -\frac{8}{21} \\ -\frac{1}{21} \end{pmatrix}^t \times \begin{pmatrix} -0.5 \\ -2 \\ -1 \end{pmatrix} = 0.25 + \frac{16}{21} + \frac{1}{21} \approx 1.06$$

而变换后分布中  $\vec{x}_w$  到原点的 Mahalanobis 距离为:

$$\vec{x}_w^T \vec{I}^{-1} \vec{x}_w = 0.5^2 + \frac{1}{6} + \frac{9}{14} \approx 1.06$$

从而得证原分布和变换后分布的距离相等。

- (e) 概率密度在某个一般线性变换下是否保持不变？换句话说，对于某线性变换  $T$ ，是否有  $p(\mathbf{x}_0 | N(\boldsymbol{\mu}, \boldsymbol{\Sigma})) = p(T^t \mathbf{x}_0 | N(T^t \boldsymbol{\mu}, T^t \boldsymbol{\Sigma} T))$ ？解释原因；

(e) 对于线性变换  $\vec{T}$ ，有

$$p(\vec{x}_0 | N(\vec{\mu}, \vec{\Sigma})) = p(\vec{T}^t \vec{x}_0 | N(\vec{T}^t \vec{\mu}, \vec{T}^t \vec{\Sigma} \vec{T}))$$

证明如下：

设原分布通过一个  $\vec{T}$  的线性变换，则变换后均值为：

$$\vec{\mu}' = \frac{1}{n} \sum_{i=1}^n \vec{x}_i'$$

$$= \frac{1}{n} \sum_{i=1}^n \vec{T}^t \vec{x}_i$$

$$= \vec{T}^t \frac{1}{n} \sum_{i=1}^n \vec{x}_i = \vec{T}^t \vec{\mu}$$

其中  $n$  为样本数， $\vec{\mu}, \vec{x}, \vec{\mu}', \vec{x}'$  分别为转换前后的均值和样本而转换后的协方差矩阵为：

$$\vec{\Sigma}' = \sum_{i=1}^n (\vec{x}_i' - \vec{\mu}') (\vec{x}_i' - \vec{\mu}')^t$$

$$= \sum_{i=1}^n (\vec{T}^t \vec{x}_i - \vec{T}^t \vec{\mu}) \times (\vec{T}^t \vec{x}_i - \vec{T}^t \vec{\mu})^t$$

$$= \vec{T}^t \left[ \sum_{i=1}^n (\vec{x}_i - \vec{\mu}) (\vec{x}_i - \vec{\mu})^t \right] \vec{T}$$

$$= \vec{T}^t \vec{\Sigma} \vec{T}$$

因此，可证通过线性变换  $\vec{T}$  后有

$$p(\vec{x}_0 | N(\vec{\mu}, \vec{\Sigma})) = p(\vec{T}^t \vec{x}_0 | N(\vec{T}^t \vec{\mu}, \vec{T}^t \vec{\Sigma} \vec{T}))$$

(也就是概率密度在某个一般线性变换下保持不变)

(f) 证明当把一个一般的白化变换  $A_w = \Phi \Lambda^{-1/2}$  应用于一个高斯分布时可保证最终分布的协方差与单位阵  $I$  成比例，检查变换后的分布是否仍具有归一化特性。

(f) 由(e)已得通过白化变换后的协方差矩阵为

$$\vec{\Sigma}' = \vec{A}_w^t \vec{\Sigma} \vec{A}_w$$

而由题知  $\vec{A}_w = \vec{\Phi} \vec{\Lambda}^{-\frac{1}{2}}$ , 设  $\vec{\Phi} = k \vec{\Lambda}$ , 其中  $\vec{\Lambda}$  为正交矩阵,  $k$  为常数  
 $\therefore \vec{\Sigma}'$  为对称矩阵则有  $\vec{\Sigma}' = \vec{\Sigma} \vec{\Lambda} \vec{\Lambda}^t$

又:  $\vec{\Lambda}$  不是对角矩阵: 也有  $(\vec{\Lambda}^{-\frac{1}{2}})^t = \vec{\Lambda}^{\frac{1}{2}}$

且:  $\vec{\Sigma}$  是正交矩阵.  $\therefore \vec{\Lambda}^t = \vec{\Lambda}^{-1}$

$$\text{因此 } \vec{\Sigma}' = \vec{A}_w^t \vec{\Sigma} \vec{A}_w$$

$$\begin{aligned} &= (\vec{\Phi} \vec{\Lambda}^{-\frac{1}{2}})^t \vec{\Sigma} (\vec{\Phi} \vec{\Lambda}^{-\frac{1}{2}}) \\ &= \vec{\Lambda}^{-\frac{1}{2}} \vec{\Phi}^t \vec{\Sigma} \vec{\Lambda} \vec{\Lambda}^t \vec{\Phi} \vec{\Lambda}^{-\frac{1}{2}} \\ &= k^2 \vec{\Lambda}^{-\frac{1}{2}} \vec{\Sigma} \vec{\Lambda} \vec{\Lambda}^t \vec{\Sigma} \vec{\Lambda} \vec{\Lambda}^{-\frac{1}{2}} \\ &= k^2 \vec{\Lambda}^{-\frac{1}{2}} \vec{\Lambda} \vec{\Lambda}^{-\frac{1}{2}} \\ &= k^2 I \end{aligned}$$

$\therefore$  变换后分布的协方差与单位阵  $I$  成比例.

另外, 变换后的分布仍具有归一化特性.

$\because$  由(e) 证明在线性变换后  $p(\vec{x}_0 | N(\vec{\mu}, \vec{\Sigma})) = p(\vec{T}^t \vec{x}_0 | N(\vec{T}^t \vec{\mu}, \vec{T}^t \vec{\Sigma} \vec{T}))$   
 即概率密度在变换后保持不变.

因此, 变换后的分布仍然保持了变换前归一化的特性.